Hermes Mini Cloud

دستیار فارسی تلگرام برای مدیریت امن کارها و یادآورها

پلتفرم	Cloudflare Workers + D1 + Cron
رابط کاربر	Telegram Bot API
هسته هوشمند	قرارداد JSON با OpenAI-compatible LLM
نوع استقرار	Serverless و بدون سرور شخصی

۱. خلاصه پروژه

Hermes Mini Cloud یک ربات تلگرامی فارسی است که پیام آزاد کاربر را به عملیات محدود و امن روی کارها تبدیل می‌کند. کاربر به‌جای حفظ کردن دستورها، طبیعی می‌نویسد؛ مثلاً «شیر را خریدم» یا «ده دقیقه دیگه یادم بنداز». مدل زبانی فقط یک پیشنهاد ساختاریافته می‌دهد و کد Worker قبل از هر تغییر، آن پیشنهاد را اعتبارسنجی می‌کند.

یادآورها نیز در D1 ذخیره می‌شوند و Cron Trigger هر دقیقه موارد موعدرسیده را بررسی و از طریق Telegram ارسال می‌کند. سامانه وضعیت را در Cloudflare D1 نگه می‌دارد؛ بنابراین بین درخواست‌ها و راه‌اندازی‌های مجدد پایدار می‌ماند.

قابلیت‌های نهایی

ویژگی	نتیجه عملی
مدیریت کار با متن فارسی	افزودن، انجام، بازگرداندن، حذف، فهرست و گفت‌وگو
رفع ابهام امن	برای ارجاع مبهم به کار، سؤال روشن‌کننده می‌پرسد و حدس نمی‌زند
یادآور پایدار	مدت نسبی فارسی، تحویل زمان‌بندی‌شده و تلاش مجدد محدود
چندکاربر مجاز	جداسازی کامل داده هر کاربر در D1 و Allow-list

تهیه‌کننده: Nasle Javan | پروژه نهایی، نسخه main

۲. معماری و تصمیم‌های طراحی

مسیر هر پیام از تلگرام شروع می‌شود. Worker ابتدا هدر امن و دسترسی کاربر را بررسی می‌کند، سپس پیام تکراری را با update_id کنار می‌گذارد. تنها پس از این کنترل‌ها، تاریخچه کوتاه و فهرست کارهای همان کاربر به مدل داده می‌شود. خروجی مدل یک JSON تک‌خطی است و پیش از اجرای هر عملیات، دوباره در Worker اعتبارسنجی می‌شود.

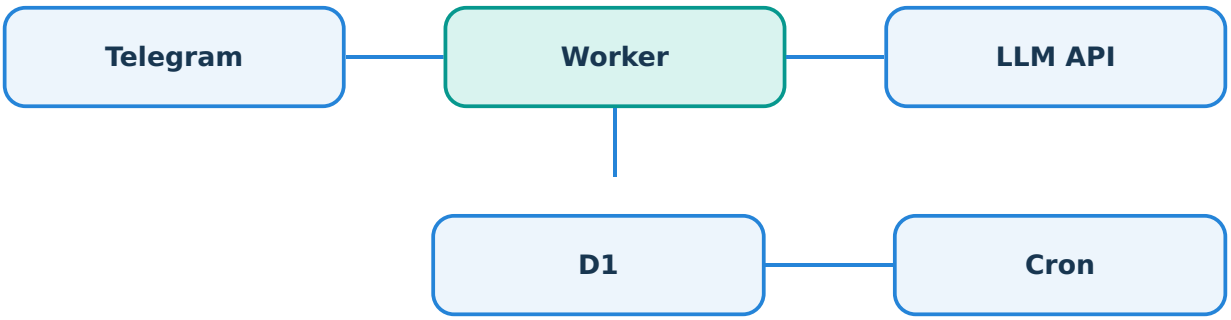

جریان عملیاتی

گام	شرح
۱	Worker با Webhook و secret header وارد می‌شود.
۲	Worker احراز هویت، allow-list و deduplication را انجام می‌دهد.
۳	مدل تنها intent ساختاریافته پیشنهاد می‌دهد؛ اختیار دیتابیس ندارد.
۴	Worker خروجی را اعتبارسنجی، عملیات را در D1 اجرا و پاسخ را به تلگرام می‌فرستد.
۵	Cron هر دقیقه فقط یادآورهای موعدرسیده را با claim اتمی بررسی می‌کند.

چرایی تصمیم‌ها

تصمیم	دلیل
Webhook به‌جای Polling	کد فقط هنگام رسیدن رخداد اجرا می‌شود؛ پردازش همیشه‌روشن و بیهوده نداریم.
Workers به‌جای VM	بار کاری کوتاه و رخدادمحور است؛ مدیریت سرور و هزینه ثابت حذف می‌شود.
D1 به‌جای KV	کارها، تاریخچه، تأییدها و یادآورها به SQL، مرتب‌سازی، ایندکس و تراکنش نیاز دارند.
State در D1	حافظه پایدار بین درخواست‌ها باید خارج از runtime ذخیره شود؛ state Worker پایدار ندارد.

۳. لایه هوشمند، امنیت و پایداری

اصل اصلی پروژه این است: «مدل پیشنهاد می‌دهد، کد اجرا می‌کند». مدل فقط یکی از actionهای ثابت add, done, undone, del, list, chat, remind را به‌صورت JSON پیشنهاد می‌کند. اگر JSON خراب باشد یا نوع داده‌ها معتبر نباشند، ربات پاسخ امن می‌دهد و هیچ داده‌ای تغییر نمی‌کند.

کنترل	نحوه اجرا
Webhook	مقایسه ثابت‌زمان secret header؛ درخواست نامعتبر با 403 رد می‌شود.
دسترسی	فقط کاربران active در authorized_users پردازش می‌شوند؛ سایر پیام‌ها ذخیره یا پاسخ داده نمی‌شوند.
مالکیت	همه queryهای کاربرمحور با telegram_user_id و پارامتر bindشده محدود می‌شوند.
عملیات مبهم	از گزینه‌ها Snapshot ده‌دقیقه‌ای ذخیره می‌شود و پاسخ بعدی بدون عبور از snapshot تعیین نمی‌شود.
حذف همه	همیشه تأیید صریح لازم دارد؛ انصراف یا پیام نامرتبط عملیات را لغو می‌کند.
ارسال تکراری تلگرام	INSERT OR IGNORE روی processed_updates با update_id از اجرای دوباره جلوگیری می‌کند.

یادآورها و مدل داده

مدت زمان یادآور از متن واقعی کاربر به‌صورت قطعی parse می‌شود، نه از عددی که مدل برگردانده است. Cron هر دقیقه حداکثر ۲۰ مورد due را می‌خواند. هر ردیف با compare-and-set claim اتمی می‌شود تا هم‌زمانی موجب ارسال تکراری نشود. در شکست Telegram، backoff خطی اعمال می‌شود و پس از پنج شکست، وضعیت failed ثبت می‌شود. claim رهاشده پس از ۱۶ دقیقه بازیابی می‌شود و همان بودجه تلاش را مصرف می‌کند.

جدول	نقش
tasks	کارها، وضعیت انجام و source_update_id برای idempotency
conversation_messages	حافظه کوتاه هر کاربر؛ نگهداری حداکثر ۳۰ پیام
authorized_users / processed_updates	دسترسی کاربران و deduplication پیام‌های تلگرام
pending_confirmations / pending_clarifications	تأیید حذف و رفع ابهام امن
reminders	زمان due، claim، retry و وضعیت ارسال

تأیید فنی ۴۱ تست regression موفق و TypeScript typecheck بدون خطا در نسخه نهایی اجرا شد.

۴. هزینه، مقیاس‌پذیری و تجربه توسعه

Cron فعلی هر دقیقه یک invocation ایجاد می‌کند. مقدار واقعی مصرف LLM وابسته به مدل و طول prompt است و باید از داشبورد Cloudflare اندازه‌گیری شود. تحلیل زیر تخمینی است و فرض می‌کند هر کاربر روزانه ۱۰ پیام می‌فرستد.

برداشت	کاربر ۱۰،۰۰۰	کاربر ۱	شاخص روزانه
در مقیاس 10,000 کاربر، مصرف Worker از سقف Free 100k/day عبور می‌کند.	حدود 101,440	حدود 1,450	درخواست Worker
خود Worker و LLM باید افقی scale شوند.	100,000	10	پیام ورودی
الگوی واقعی باید پایش شود؛ ممکن است سقف 100k write/day رد شود.	در حد صدها هزار	در حد ده‌ها	نوشتن D1 - تخمینی
سهمیه رایگان روزانه 10k neurons است؛ پیش از رشد باید اندازه‌گیری شود.	اولین گلوگاه محتمل	وابسته به مدل	Workers AI

نتیجه هزینه

برای یک کاربر شخصی، طراحی کاملاً مناسب پلن رایگان است. در مقیاس ۱۰،۰۰۰ کاربر، خود تعداد درخواست‌های Worker به مرز یا بالای Free plan می‌رسد و D1 write و مصرف LLM نیز باید با telemetry واقعی کنترل شوند. راه‌حل رشد، Workers Paid، پایش D1 row metrics، کوتاه کردن prompt و انتخاب مدل متناسب با کیفیت موردنیاز است.

چالش‌ها و آنچه یاد گرفتم

چالش	راه‌حل مهندسی
خروجی نامعتبر LLM	قرارداد JSON سخت‌گیر، parser، allow-list action و fallback بدون write.
ارجاع مبهم مانند «همون یکی»	مدل به‌جای اعتماد به task_id، snapshot قطعی و guard clarification.
تحویل دوباره Telegram	claim اتمی update_id و idempotent task creation.
عدم ارسال یادآور	claim اتمی، recovery ۱۶ دقیقه‌ای، retry محدود و وضعیت failed قابل مشاهده.
وابستگی به زمان	ذخیره‌سازی UTC و نمایش context برای Asia/Tehran.

منابع فنی: Cloudflare Workers Limits، Cloudflare D1 Pricing، Cloudflare Cron Triggers و Workers AI Pricing. آدرس: developers.cloudflare.com | تاریخ دسترسی: 05-11-2026.